DOCUMENTO DI HANDOFF & ARCHITECTURE REVIEW

Progetto DH: "Oscar al Miglior Film"

Dominio Scelto:	Cinema / Premio Oscar al Miglior Film (Academy Awards)	**Data Handoff:**	27 Luglio 2026
Corso:	Digital Humanities & Web Scraping	**Status:**	DEFINIZIONE ARCHITETTURA

1. SINTESI ESECUTIVA E OBIETTIVI

A seguito della sessione di orientamento per la scelta del dominio applicativo, è stato selezionato il dataset del **Premio Oscar al Miglior Film (Academy Award for Best Picture)**. Questo dominio garantisce un'elevata ricchezza informativa ("dati corposi"), strutturata e non strutturata, ideale per soddisfare i stringenti requisiti metodologici del corso di Digital Humanities senza sovrapporsi al caso di studio classico (Premio Strega).

2. MOTIVAZIONE METODOLOGICA DELLA SCELTA

Perché questo dataset risponde perfettamente alle direttive:

- **Scalabilità e granularità:** Presenza di tabelle riassuntive pluridecennali e pagine di dettaglio per ogni singolo film, regista, e casa di produzione.
- **Complementarità di dati:** Permette di combinare metriche quantitative (incassi, durata, anno, età dei registi) e analisi qualitative (sinossi, temi, ambientazioni).
- **Struttura analoga e migliorata:** Ricalca la logica del Premio Strega (albo d'oro + schede biografiche) con un volume di dati nettamente superiore e internazionale.

3. MAPPATURA DEL PROGETTO SULLE FASI DI CORSO

Fase Progetto	Attività Tecniche	Output / Deliverable
Fase 0 & 1: Scraping & Cleaning	• Scraping della pagina principale dell'Albo d'Oro degli Oscar su Wikipedia. • Estrazione della tabella dei film vincitori (Anno, Titolo originale, Regista, Casa di produzione). • Pulizia stringhe, gestione note a piè di pagina e normalizzazione date.	Dataset tabellare di base (`oscar_best_pictures.csv`) pulito e validato.
Fase 2: Scraping a Cascata	• Download automatico (crawler) delle sottopagine di ogni film vincitore e dei rispettivi registi. • Estrazione dati da Infobox: data/luogo nascita regista, durata film, budget, incassi, genere, paese.	Database relazionato/esteso contenente attributi biografici e cinematografici di dettaglio.
Fase 3: Analisi Descrittiva	• Calcolo età media dei registi al momento della vittoria. • Trend temporali sulla durata media dei film premiati nei vari decenni. • Distribuzione geografica dei registi e prevalenza delle case produttrici.	Dashboard visuale, grafici aggregati e metriche descrittive quantitarive.
Fase 4: Analisi Qualitativa (LLM)	• Estrazione delle sezioni "Trama/Sinossi" dalle pagine dei film. • Invio dei testi via API LLM per estrazione strutturata di: macro-temi (es. guerra, dramma familiare, storia vera), epoca/ambientazione e tono narrativo.	Dataset arricchito con marcatori semantici per analisi di storia culturale e del cinema.

4. PROSSIMI PASSI OPERATIVI

1. Configurazione dello script di scraping iniziale con `BeautifulSoup` / `requests` sulla pagina principale dell'Albo d'Oro.
2. Definizione dello schema di pulizia dati per gestire le incoerenze nelle tabelle storiche (es. anni di cerimonia vs anni di uscita del film).
3. Pianificazione della pipeline di chiamate API per la Fase 4 (definizione del prompt JSON-structured per l'LLM).